# **BDD** KIT APPRENANT



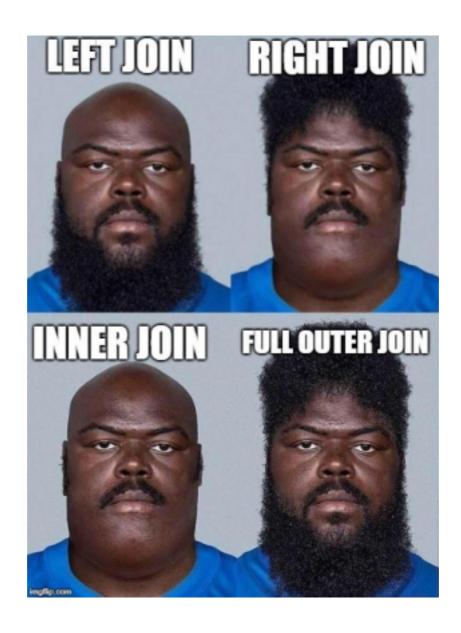








# Base de Données (BDD)



TYPE OF SQL JOINTS (SOURCE: HTTPS://www.reddit.com/r/Database/)

# Objectifs du module

# Maîtriser les concepts et l'utilisation d'un SGBD

Le stockage de l'information fait partie des challenges actuels et historiques de l'informatique. Plusieurs générations de chercheurs en informatique ont travaillé - et travaillent encore - à modéliser et optimiser les systèmes de stockage, selon différents types de contraintes.

Dans l'histoire de l'informatique, le besoin d'un système de stockage performant et présentant les caractéristiques suivantes s'est fait ressentir très tôt :

- Structuré : Un schéma clair et précis des chemins d'accès aux données est réalisable;
- Massif: Un grand nombre de données peut être géré. Aujourd'hui, on parle de téraoctets/jour;
- **Persistant** : Il reste stable et pérenne, *a contrario* des programmes informatiques dont l'état est perdu après la fermeture de l'application;
- Sécurisé: Il présente des sécurités contre les failles tant au niveau logiciel (software) que physique (hardware) --> sauvegardes fréquentes, ...;
- **Concurrent** : La même base de données reste accessible à plusieurs utilisateurs en même temps sans risque pour son intégrité;
- **Efficient**: d'abord la performance, puis la performance et finalement la performance bons résultats avec un minimum d'efforts:

Les systèmes RDBMS (*Relational Database Management Systems*) ou SGBD en français ont permis de répondre à ces besoins. Ils sont issus du modèle de données relationnel décrit par Edgar Codd en 1969.

# Pourquoi apprendre les SGBDR?

#### Méthode de stockage privilégiée dans le monde industriel

Il est à 90% probable que les systèmes informatiques avec lesquels vous interagissez ou interagirez dans votre vie quotidienne utilisent au moins un SGBD pour sauvegarder l'information.

<u>Transformation de l'informatique : d'une science de calcul vers une science de la donnée</u>

Autrefois, la donnée n'avait qu'un but opérationnel précis : enregistrer une opération, afin de faire constater un évènement/état. De nos jours, la donnée est plus qu'un répertoire d'octets, mais une opportunité d'extraction de connaissances.

# **Compétences**

À la fin de ce module vous serez en mesure de :

- Comprendre une partie des généralités et la terminologie associées aux domaines de l'architecture et l'ingénierie Data
- Exploiter un SGBD à l'aide du langage de programmation SQL pour :
  - o Définir un schéma relationnel (*Data Definition Language*)
  - o Manipuler la donnée (Data Manipulation Language)
- Vous connecter à un SGBD :
  - o À l'aide d'un client GUI
  - o À l'aide du langage de programmation python
- Maîtriser les diagrammes de classes du langage de modélisation unifié (UML) pour:
  - o Comprendre l'architecture d'une BDD relationnelle
  - o Concevoir une BDD relationnelle
- (Optionnel) Avoir des notions de normalisation :
  - o 1NF, 2NF, 3NF
  - o 0 4NF

# **Organisation**

### Itération #1 (½ jour PM)

- Travail en équipe, par îlot, réflexion sur les mots :
  - o Données
  - o Modèle de données
  - o Structuration de données
  - o Base de données
  - o SQL / noSQL

# Itération #2 (1 jour)

- Synthèse des notions évoquées lors de l'itération 1
- En autonomie : Manipulation des données en SQL (site web sqlzoo)

# Itération #3 (1 jour)

- AM: S'interfacer avec une BDD
- PM: Travail en équipe, par îlot
  - • Pour le jour 3, pensez à prendre des écouteurs et des crayons!
  - Lecture d'un diagramme UML
  - Complétion d'un diagramme UML

# Itération #4 (1 jour)

• Créer un script pour alimenter une BDD

# Itération 1 (½ jour)

# Introduction: BDD, SQL et noSQL

# Objectif(s):

- Apprendre à utiliser le sous-ensemble du langage SQL pour la manipulation de données
- (Optionnel) : Avoir des notions d'algèbre relationnelle

### Quelques éléments de langage pour débuter..à vous de compléter!

Le modèle des données relationnel peut se décrire comme suit :

- C'est un ensemble de **relations** (i.e. des tables)
- Chaque relation contient un ensemble d'attributs (i.e. colonnes)
- Une relation contient des **tuples** (i.e. lignes) avec des valeurs pour chaque attribut
- Chaque attribut est **typé**, et le type est souvent *atomique* (e.g. *entier, réel, etc.*)

Un schéma est la description structurelle d'une base relationnelle.

**Une clé** est un attribut (ou ensemble d'attributs) qui permet d'accéder à un ensemble de tuples.

Une clé primaire est un attribut (ou ensemble d'attributs) qui permet d'identifier un seul et unique tuple.

**SGBD** - Le système de gestion de base de données relationnelle est un système qui permet de stocker l'information sous un modèle de données relationnelles.

Parmi les SGBD très connus et utilisés se trouvent : Oracle, SQL Server, PostgreSQL, MySQL et SQL : STructured Ouery Language est le language qui permet d'exploiter un SGBD.

#### SQL est un langage:

- **Déclaratif**: Nous énonçons ce que l'on cherche et non pas le comment ; c'est le travail du SGBD de trouver l'algorithme pour donner le bon résultat de manière optimale. De ce fait, on dit que SQL est un langage de haut niveau.
- Normalisé: En théorie une requête doit pouvoir s'exécuter sur les différents SGBD. Dans la pratique, selon la complexité de la requête, elle sera modifiée pour s'ajuster à l'opinion du SGBD. Les changements sont, en règle générale, simples.
  - La norme ISO 9075 définit des fonctionnalités obligatoires et optionnelles du langage. Les SGBD implémentent ces fonctionnalités, a minima celles obligatoires, et ajoutent généralement leurs propres spécificités.

SOL est un langage issu de l'algèbre relationnelle.

# Consignes

- Répondre aux questions suivantes:
  - Ou'est-ce qu'une donnée?
  - Comment définir une base de données?
  - Existe-t-il différents types de données? Si oui, lesquels connaissez-vous?
  - Pourquoi utiliser un SGBD?
  - Quelles sont les principales différences entre SQL et noSQL? Pourquoi choisir l'un plutôt que l'autre? Des exemples de cas réels ?
- Réaliser un tableau de synthèse des avantages et inconvénients de différents SGBD.
- Petit test de fin de journée: <a href="https://librecours.net/module/bdd0/intro-sgbd/quiz.xhtml">https://librecours.net/module/bdd0/intro-sgbd/quiz.xhtml</a>

# Quelques éléments de lecture

Si vous avez envie d'un peu de théorie, vous pouvez commencer à lire ou écouter les ressources suivantes : R1.1 et R1.2.

#### Références / Ressources

#### R1.1 Databases

https://datascientest.com/base-de-donnees-definition
Database systems - Cornell University Course

# R1.2 Relational Algebra

https://slideshowes.com/doc/159317/relational-algebra---university-of-toronto

https://www.youtube.com/watch?v=tii7xcFilOA

https://www.youtube.com/watch?v=GkBf2dZAES0

# Itération 2 (1 jour)

N'hésitez pas à revoir et implémenter les éléments de théorie investiguer lors de la première itération avant de débuter.

# Découverte de SQL - (1 jour)

Définition de SQL: ? à remplir par l'apprenant!

### **Consignes**

- Rafraîchissement des notions découvertes lors de l'itération 1: Questionnaires via Plickers
- <u>Direction https://sqlzoo.net/ afin de réaliser les exercices 0 jusqu'à 9.</u>
  - $\rightarrow$  « 9 Window function », et «  $\phi$  9+ Covid » ne sont pas obligatoires, mais si vous êtes curieux, foncez !

Pour éviter de perdre votre travail. Vous pouvez créer un compte avec votre e-mail Campus.

# Quelques éléments de lecture

SQL est un langage assez intuitif. Il est cependant possible que vous bloquiez au niveau des jointures. Dans ce cas, vous pouvez consulter la R2.1.

#### Références / Ressources

R2.1 SQL & Jointures – Université de Lyon <a href="https://sql.sh/ressources/cours-sql-sh-.pdf">https://sql.sh/ressources/cours-sql-sh-.pdf</a> <a href="https://sql.sh/2401-sql-join-infographie">https://sql.sh/2401-sql-join-infographie</a>

Ensuite à vous de trouver vos cheat-sheet....;-)

# Itération 3 (2 jour)

# S'interfacer à une BDD (AM)

# Objectifs proposés:

Se servir d'une BDD à l'aide des différents outils :

- à l'aide d'une interface visuelle (GUI),
- à l'aide du langage Python et avec la librairie Pandas.
- (optionnel) quels outils pour quel besoin?

# Consignes

Pour cette itération, nous allons utiliser le logiciel SQLite. SQLite est un SGBD, sa qualité principale est la légèreté du système. Il est très probable que certaines des applications mobiles installées dans votre téléphone utilisent SQLite pour stocker l'information.

C1 - Installation de SQLite

C1.1: Sur machine Linux

\$ sudo apt-get install sqlite3

\$ sudo apt-get install sglitebrowser

Ouvrir I'app Ubuntu Software Application > Chercher DB Browser for SQLite > Installer



sqlitebrowser ★★★★ SQLite Database Browser is a visual tool used to create, design and edit database files compatible with SQLite. Its interface is based on QT, and is meant to be used for users an...

#### C1.2: Sur machine Windows

Pour ceux avec une machine Windows, vous allez installer SQLite en même temps que «DB Browser for SQLite » .

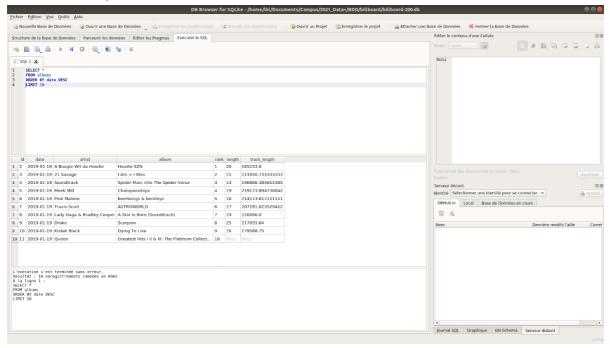
«DB Browser for SQLite » est un client visuel (i.e. GUI) pour les BDD de type SQLite. Un client visuel est un programme capable de se connecter à un SGBD, et de simplifier notamment l'étape de compréhension d'une BDD.

Pour l'installer dans une machine Windows :

- 1. Téléchargez DB.Browser.for.SQLite-3.12.1-win64.zip
- 2. Décompresser le fichier Zip
- 3. Cliquer sur l'exécutable DB Browser for SQLite

#### C2 - S'interfacer avec un GUI

- 1. Téléchargez les données qui se trouvent dans la ressource R3.1
- 2. Connectez-vous à la BDD à l'aide de votre client (i.e. DB Browser for SQLite)
- 3. Pour comprendre les données, référez-vous aux ressources R3.2 et R3.3
- 4. Trouvez le top 10 albums des 20 dernières années.



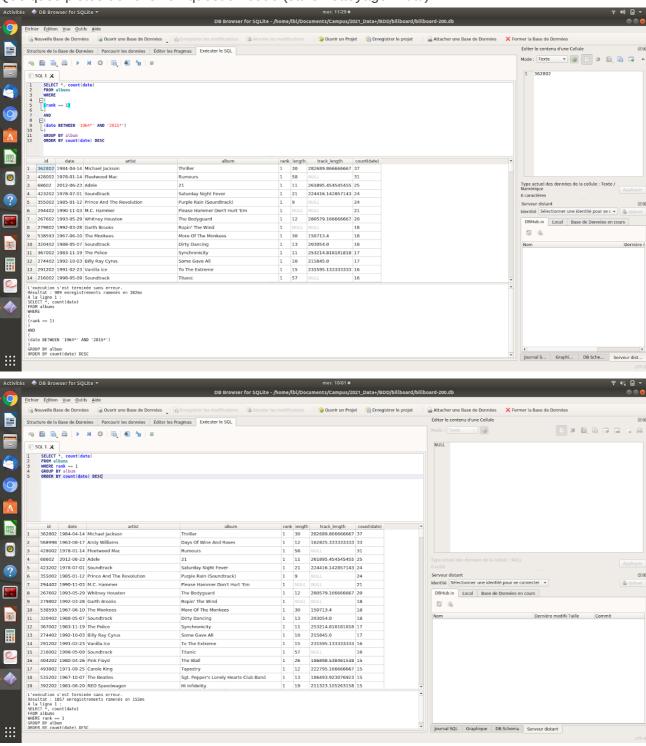
5. Fact checking. Vérifiez à l'aide de requêtes SQL les informations de la ressource R3.2.

#### Attention:

- Aux valeurs dans chaque colonne
- Aux duplicatas
- Aux erreurs de syntaxe dans les cases
  - a. Most weeks at Number One.
  - b. Top 10 albums of All-Time. Idem que le point 4, mais sans conditions sur les dates.
  - c. (Bonus) Tout autre qui vous semble intéressant!

Attention : Peut être que certains attributs doivent être modifiés afin que vos requêtes s'exécutent correctement.

Quelques pistes de réflexion question code (sans nettoyage initial):



#### C3 - S'interfacer avec Python

1. Créer un jupyter notebook

#### → https://drive.google.com/file/d/18GP3Lcp29ZMk8pltunBm1GgK5Edo4dcR/view?usp=sharing

- 2. Connectez-vous à la base de données à l'aide du module sglite3.
  - a. Utilisez la ressource R3.4 pour comprendre le module sqlite sur Python
  - b. Créez une fonction ou une classe qui vous permet de facilement de :
    - i. Se connecter à votre BD
    - ii. Effectuer une requête
    - iii. Récupérer le résultat
- 3. Effectuez des requêtes SQL depuis Python.
  - a. Pour tester le bon fonctionnement
  - b. Puis pour répondre aux questions proposées en 2

#### C4 - S'interfacer avec Pandas

Il est possible de créer un dataframe à partir d'une requête SQL (cf R3.5).

Créez une seule requête SQL, et à l'aide de pandas répondez aux questions suivantes :

- 1. Effectuez la moyenne par année de toutes les caractéristiques. Quelle est la tendance que vous constatez?
- 2. Quelle est l'année dont le niveau sonore «loudness » a été le plus haut ?
- 3. Quelle est la clé musicale la plus populaire en prenant en compte le mode (e.g. majeur, mineur)?



Bonus → tracez des courbes.

Quel graphique vous permet de mieux comprendre la popularité des tonalités, en faisant la différence entre majeur et mineur par note?

# Références / Ressources

R 3.1 – Données Billhoard 200

https://www.dropbox.com/s/z6bcckb74k0d97f/billboard.zip?dl=0

R 3.2 – C'est quoi Billboard 200 ?

https://en.wikipedia.org/wiki/Billboard 200

R 3.3 – Documentation sur les features de chanson par Spotify

https://developer.spotify.com/documentation/web-api/reference/tracks/get-audio-features/

R 3.4 – Module Sglite sur Python 3.6

https://docs.python.org/3.6/library/sglite3.html

R 3.5 – Dataframe from SQL

https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.read\_sql.html

# Modélisation d'une BDD - (PM)

# Objectifs proposés:

- Lire un diagramme de BDD
- Traduire un diagramme en schémas (instructions SQL)
- Savoir insérer des données:
  - o à l'aide de Python (Pandas)
  - o d'un fichier SQL (bulk insert)

# Consignes

Pour cette itération, nous allons utiliser le logiciel SQLite. SQLite est un SGBD, sa qualité principale est la légèreté du système. Il est très probable que certaines des applications mobiles installées dans votre téléphone utilisent SQLite pour stocker l'information.

C5.1 - Lire et compléter un diagramme UML

C5.1.1: Un peu de lecture

Prenez du temps pour étudier les ressources R3.6 et R3.7

C5.1.2: Discussion

La suite se déroule en équipe, par îlot et se focalise sur le document ci-dessous. Ce diagramme de classes correspond à la structuration de la donnée pour le système de transport d'une ville.

Remarque : Système de transport != Système GPS.

Il ne s'agit donc pas d'un diagramme concernant les résultats d'un calculateur d'itinéraire tels que Google Maps.

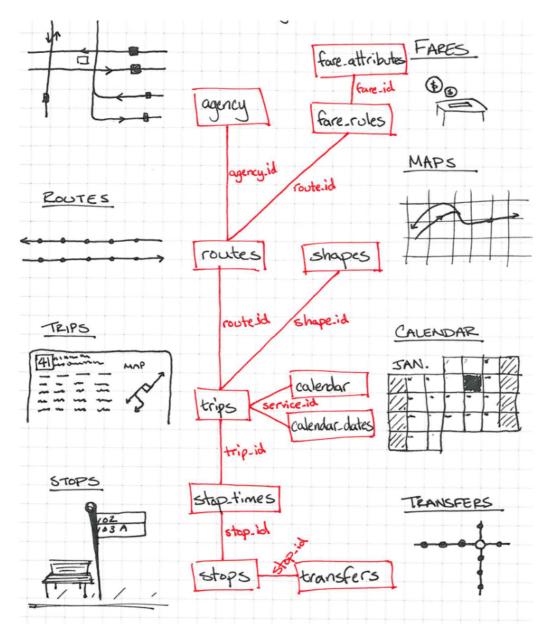


Figure 3.1 - Structuring transport systems

# C5.1.3: Diagramme

Le diagramme manque d'une information clé: la multiplicité des associations. En équipe, retrouvez les multiplicités des associations suivantes:

- a. Agency Routes
- b. Trips StopTimes
- c. StopTimes Stops
- d. Trips Calendar
- e. Trips Frequencies

Pour mieux comprendre la logique métier, vous pouvez vous appuyer sur la ressource R3.8 et R3.9.

#### C5.2 - Création d'un schéma

Toujours en équipe, travaillez ensemble pour traduire votre diagramme de classes en un fichier SQL, lequel sera nommé "gtf schema.sql". Les classes à traduire sont les suivantes:

- 1. Agency
- 2. Routes
- 3. Trips
- 4. StopTimes
- 5. Stops
- → ex: https://gist.github.com/denysvitali/cf33fb42c3cfd26c0aabc8e849f8252d

Une fois votre schéma finalisé, réalisez les opérations suivantes:

- 1. Créer une BDD nommée "gtfs tag.db"
- 2. Exécuter votre schéma sur votre BDD
- 3. Vérifier, à l'aide du GUI, que vos instructions ont bien été prises en compte

Pour réussir cette étape, privilégiez la compréhension de la ressource R3.8. Utilisez R3.10 pour Commencer votre schéma, et R3.11 pour l'exécuter.

#### C5.3 - Insertion des données via Pandas

En autonomie, vous insérerez l'information correspondant aux classes:

- agency
- stops

Pour ce faire, vous utiliserez la méthode pandas permettant d'insérer des données dans une BDD.

#### C5.4 - Insertion des données (bulk insert)

En autonomie, vous travaillerez avec les données GTFS du réseau TAG (ressource R3.12). Votre mission sera d'insérer les données pour les classes suivantes:

- trips
- stoptimes

Voici les étapes à suivre pour ce faire (e.g. stops.txt):

- 1. Créer, en python, un fichier SQL (e.g. insert\_stops.sql)
- 2. Exécuter le fichier dans la BDD

Des précisions concernant ces étapes sont présentées page suivante.

→ https://drive.google.com/file/d/1iM0lzyKzPspP9AmnkAzO-fMloiwvqPXY/view?usp=sharing

# Étape 3.4.1 - implémenter une fonction qui génère une commande insertion SQL

# Sa signature est la suivante :

def gen\_insert\_query(table\_name:str, a\_dict:dict) -> str

Les paramètres de cette fonction sont :

• tablename : le nom de la table (e.g. gtfs stops)

• a\_dict : dictionnaire Python

Elle retourne une chaîne de caractère qui représente l'insertion SQL.

### Étape 3.4.2 - implémenter une fonction qui génère des commandes d'insertion SQL

### Sa signature est la suivante :

def get\_insert\_queries(tablename:str, df: pd.DataFrame) -> list

Les paramètres de cette fonction sont :

- tablename : le nom de la table (e.g. gtfs stops)
- df : le dataframe pandas

Elle retourne une liste de chaînes de caractère qui représente les insertions SQL correspondant au dataframe.

# Étape 3.4.3 - implémenter une procédure qui crée un fichier SQL

#### Sa signature est la suivante :

def gen insert file(filename, tablename, df)

Les paramètres de cette procédure sont :

- filename : est le nom de fichier (e.g. insert stops.sql)
- tablename : le nom de la relation où nous allons insérer nos tuples (e.g. gtfs stops)
- df : un dataframe pandas

#### Étape 3.4.4 – Exécutez votre fichier SQL sur la BDD

Afin de rendre la transaction de votre fichier SQL efficace, regardez les mots clés BEGIN et COMMIT du langage SQL.

#### C3.5 - Réflexions

Vous avez inséré des données avec deux méthodes différentes (pandas, bulk Insert):

- 1. Quelle méthode est plus rapide et facile à implémenter ?
- 2. Quelle méthode est plus rapide pour insérer l'information?
- 3. Dans quel scénario préconisez-vous l'utilisation d'une méthode ou l'autre ?

C3.6 - ( Bonus ) Créer un calculateur d'itinéraire

#### À partir de :

- A Un point GPS de départ, en format tuples de float;
- B Un point GPS d'arrivée, en format tuples de float;
- H une heure de part en format datetime;

Calculez l'itinéraire des lignes TAG à prendre.

#### Références / Ressources

R 3.6 – Diagrammes des classes (UML) - Stanford <a href="https://www.youtube.com/watch?v=LmS4Y99fNaQ">https://www.youtube.com/watch?v=X89KLfrNOPo</a>

#### R 3.7 – Référence diagrammes de classes – Microsoft

 $\underline{https://docs.microsoft.com/en-us/visualstudio/modeling/uml-class-diagrams-reference?view=vs-\underline{2015}$ 

### R 3.8 - Référentiel GTFS

https://developers.google.com/transit/gtfs/reference

#### R 3.9 - GTFS en dessin

https://xang1234.github.io/isochrone/

#### R 3.10 – Exemple de schéma sql

https://www.dropbox.com/s/t4s7fuo0fxynjqk/schema.sql?dl=0

#### R 3.11 – Introduction à SQLite

https://www.youtube.com/watch?v=qiAMt8Tj-84

https://www.youtube.com/watch?v=xyCxLKEQPAs

#### R 3.12 - GTFS Réseau TAG

https://www.data.gouv.fr/fr/datasets/horaires-theoriques-du-reseau-tag/ -> data files for the job

Quelques lectures complémentaires:

- https://drive.google.com/drive/folders/1uAVFUAS-tnDwRrbMlxjBmUP8ONIYzudu?usp=sharing
- https://www.youtube.com/watch?v=ruz-vK8lesE
- https://towardsdatascience.com/arm-yourself-to-select-your-first-database-8bc9008bf8ec
- https://www.ionos.fr/digitalguide/sites-internet/developpement-web/diagramme-de-classes-uml/

Les attaques par injection de SQL : qu'est-ce que c'est, comment s'en protéger en Python <a href="https://realpython.com/prevent-python-sql-injection/">https://realpython.com/prevent-python-sql-injection/</a>

⇒ Prenez l'habitude d'écrire vos requêtes SQL en respectant les bonnes pratiques

Les contraintes: à quoi ça sert, quels sont les types utilisables https://vertabelo.com/blog/database-constraints-types/

Un élément fondamental des bases de données : les index <a href="http://cerig.pagora.grenoble-inp.fr/tutoriel/bases-de-donnees/chap03.htm">http://cerig.pagora.grenoble-inp.fr/tutoriel/bases-de-donnees/chap03.htm</a>

⇒ Ce lien n'est qu'une introduction, le sujet est vaste, mais il est utile d'en comprendre au moins les bases!

# **Bonus**

Pour ceux ayant déjà fini à ce stade, 2 options:

- 1 Créer une BDD avec les données RTE
- 2 Commencer une sensibilisation au noSQL: <a href="https://datascientest.com/nosql-tout-savoir">https://datascientest.com/nosql-tout-savoir</a>

# Puis:

A vos remarques: <a href="https://notes.parinux.org/BDD">https://notes.parinux.org/BDD</a>